

V5 Transformer Baseline 实验结果与分析

周润天

2026 年 8 月 12 日

1 实验背景

在前期 V1/V2 研究中，项目已经完成了较完整的 A 股个股横截面收益预测框架。V1 主要采用两阶段建模方法，第一阶段使用 Gaussian HMM 识别市场状态，第二阶段使用 OLS、Ridge 和 Kernel Ridge 等模型预测个股未来收益，并比较日频量价、5min、基本面、集合竞价和市场状态变量等不同信息源的边际贡献。

V2 进一步强调严格因果性和样本外评估。其核心思想是：所有特征必须严格使用预测时点之前的信息，避免未来信息泄露；模型评估采用 walk-forward 滚动窗口方式；所有模型统一使用同一套评估口径，包括 Rank IC、ICIR、分层组合收益、换手率、扣费后收益、夏普比率和最大回撤等指标。

在 V2 已有实验中，线性 Ridge 模型表现较强，而 Kernel Ridge、两层全连接神经网络和梯度提升树等非线性模型并未稳定超过线性基线。因此，本次 V5 实验的目的不是简单验证“深度模型是否更好”，而是进一步检验 Transformer 这种序列模型是否能够利用历史量价路径信息，提取普通 MLP 和 Kernel Ridge 没有捕捉到的时序结构。

2 实验设置

本次 V5 版本新增了一个 Transformer baseline，用于预测下一交易日收益。预测目标为：

$$Y_{i,t+1} = r_{i,t+1}$$

其中， $Y_{i,t+1}$ 表示股票 i 在下一交易日的收益率。

模型输入为每只股票过去 20 个交易日观测的基础量价序列，特征包括：

- `return_5d`: 过去 5 日收益率;
- `return_10d`: 过去 10 日收益率;
- `return_20d`: 过去 20 日收益率;
- `turnover_20d_mean`: 过去 20 日平均换手率;
- `log_neg_market_value`: 对数流通市值。

因此, 每个样本的输入可以表示为:

$$X_{i,t-19:t} = [x_{i,t-19}, x_{i,t-18}, \dots, x_{i,t}]$$

其中, 每个 $x_{i,t}$ 是一个 5 维特征向量。模型使用 Transformer Encoder 对该 20 日历史序列进行编码, 并输出下一交易日收益预测值:

$$\hat{Y}_{i,t+1} = f_{\text{Transformer}}(X_{i,t-19:t})$$

实验采用 walk-forward 样本外评估方式。每个窗口使用 504 个交易日作为训练期, 之后设置 5 个交易日 embargo, 再用后续一个自然月作为测试期。每个窗口内, winsorization 边界和标准化参数均只在训练集内部拟合, 测试集沿用训练期参数, 从而避免未来信息泄露。

由于 A 股全市场样本规模较大, 为控制训练时间, 每个 rolling window 的训练序列数量上限设为 120000 条。最终该实验共评估 4,440,862 条有效样本, 覆盖 931 个测试交易日。

3 Transformer 模型结构

本次实验采用 Transformer Encoder sequence regressor。模型结构可以概括为:

$$\text{Historical feature sequence} \rightarrow \text{Transformer Encoder} \rightarrow \text{Prediction Head} \rightarrow \hat{r}_{t+1}$$

Transformer Encoder 的核心是 Multi-Head Attention。相比普通 MLP 只处理静态截面特征, Transformer 可以直接处理历史序列, 并通过注意力机制自动学习不同历史时点之间的关系。

在量化预测中，不同 attention head 可以理解为从不同角度观察历史量价序列。例如，某些 head 可能更关注短期反转信号，某些 head 可能更关注中期趋势，某些 head 可能更关注换手率变化，也可能有 head 更关注市值和流动性结构。

因此，本次实验主要检验以下问题：

历史量价序列 + Multi-Head Attention 是否能够提升个股横截面收益预测效果？

4 样本外预测结果

V5 Transformer baseline 的主要测试结果如下表所示。

表 1: V5 Transformer Baseline 样本外结果	
指标	数值
有效评估样本数	4,440,862
测试交易日数	931
Rank IC Mean	0.038227
Rank IC Std	0.142991
ICIR	0.267340
IC 为正比例	60.47%
方向准确率	50.21%
MSE	0.001129
Top 组年化收益	32.30%
Bottom 组年化收益	-3.16%
Top-Bottom 毛年化收益	35.46%
Top-Bottom 扣费后年化收益	29.30%
扣费后复合年化收益	32.39%
年化波动率	15.68%
Sharpe	1.869117
最大回撤	-23.90%
Top 组平均换手率	25.29%
Bottom 组平均换手率	23.45%

从横截面排序指标来看，Transformer 的 Rank IC Mean 为 0.038227，IC 为正比例为 60.47%。这说明模型在样本外具有正向排序能力，但排序强度仍然有限。

从组合端表现来看，Top-Bottom 扣费后年化收益为 29.30%，Sharpe 为 1.869117，最大回撤为-23.90%。这说明 Transformer 虽然没有达到最强线性基线的水平，但已经能够形成较稳定的正向多空组合收益。

5 图形结果解读

从分组收益图可以看出，预测分组收益整体呈现较清晰的单调性。最低预测组 group 1 的年化收益为负，而 group 2 到 group 5 的收益逐步上升，最高预测组 group 5 的年化收益最高。这说明 Transformer 输出的预测分数并不是随机噪声，而是对股票未来相对强弱具有一定区分能力。

从训练损失曲线来看，多数 rolling window 的 training loss 随 epoch 增加而下降，说明模型在训练集上能够学习到一定规律，没有出现明显训练崩溃。但需要注意，训练 loss 下降并不等同于样本外预测能力提升，因此最终判断仍应以 Rank IC、ICIR、扣费后收益、Sharpe 和最大回撤等样本外指标为准。

从 Top-Bottom 多空净值曲线来看，毛收益和扣费后收益均长期向上。扣费后 NAV 从 1 附近上升到约 2.7 左右，说明在考虑交易成本后，Transformer 预测信号仍然能够形成正向累计收益。但毛收益与扣费后收益之间存在明显差距，说明换手率和交易成本仍然是影响策略可实现性的重要因素。

从 Daily Rank IC 图来看，日度 Rank IC 波动较大，既有较高正值，也存在明显负值区间。20 日均线大部分时间处于 0 附近或 0 以上，说明模型整体存在正向预测能力，但稳定性不够强。这也解释了为什么 Transformer 能够获得正向多空收益，但 ICIR 只有 0.267340，仍低于 V2 中的最强线性基线。

6 与 V2 原有模型的对比

V2 中已经对线性基线、Kernel Ridge 和两层全连接网络进行了统一口径对比。原 V2 结果显示，线性 Ridge 基线的 IC 均值为 0.062331，ICIR 为 0.399984，多空净年化 36.96%，Sharpe 为 1.997065；Kernel Ridge 的 IC 均值为 0.031812，Sharpe 为 1.280519；两层全连接 MLP 的 IC 均值为 0.028604，Sharpe 为 1.561298。

将 V5 Transformer 与这些模型对比，可以得到如下结果。

表 2: V5 Transformer 与 V2 原有模型对比

模型	IC / Rank IC	ICIR	多空净年化	Sharpe	最大回撤
Ridge 线性基线	0.062331	0.399984	36.96%	1.997065	-29.13%
Kernel Ridge	0.031812	0.296962	15.08%	1.280519	-15.64%
两层全连接 MLP	0.028604	0.301691	16.53%	1.561298	-13.26%
Transformer baseline	0.038227	0.267340	29.30%	1.869117	-23.90%

从结果看，Transformer 明显优于 V2 中原有的 Kernel Ridge 和两层全连接 MLP。

Transformer 的 Rank IC 为 0.038227, 高于 Kernel Ridge 的 0.031812 和 MLP 的 0.028604; 其 Top-Bottom 扣费后年化收益为 29.30%, 也明显高于 Kernel Ridge 的 15.08% 和 MLP 的 16.53%。这说明, 相比普通非线性模型, Transformer 的序列结构确实更有能力提取历史量价路径中的信息。

但同时, Transformer 仍未超过 Ridge 线性基线。Ridge 的 IC 为 0.062331, 明显高于 Transformer 的 0.038227; Ridge 的多空净年化收益为 36.96%, 也高于 Transformer 的 29.30%; Ridge 的 Sharpe 为 1.997065, 也略高于 Transformer 的 1.869117。因此, 当前版本不能得出 “Transformer 全面优于线性模型” 的结论。

7 阶段性结论

本次 V5 Transformer baseline 的实验结果可以总结为三点。

第一, Transformer 作为序列模型是有效的。它在样本外获得了正向 Rank IC、正向 IC 为正比例、正向分层收益和较高的多空扣费后收益, 说明模型确实从过去 20 日基础量价序列中学习到了了一定的横截面排序信息。

第二, Transformer 明显好于 V2 中原有的普通非线性模型。相比 Kernel Ridge 和两层全连接 MLP, Transformer 在 Rank IC、扣费后年化收益和 Sharpe 上都有明显提升。这说明 Multi-Head Attention 和序列建模机制相比普通 MLP 更适合处理历史量价路径信息。

第三, Transformer 暂时还没有超过最强的 Ridge 线性基线。V2 的重要结论之一是: 在严格滞后的信息集下, 五个基础量价特征的线性模型已经具备稳定的正向横截面排序能力, 而多种非线性模型均未能稳定超越线性基线。本次 Transformer 的结果虽然改善了普通非线性模型的表现, 但仍低于 Ridge baseline, 说明当前 Transformer 版本还没有充分转化序列建模优势。

因此, 本阶段结论是: Transformer 不是无效模型, 它已经证明了序列结构和 attention 机制相比普通 MLP 具有增量价值; 但它目前还不能替代 Ridge baseline。后续需要进一步优化特征输入、模型结构和组合层信号处理, 才能判断 Transformer 是否具有超过线性基线的潜力。

8 后续改进方向

后续可以在当前 V5 Transformer baseline 基础上继续做三个方向的改进。

第一, 加入 HMM 状态概率, 构造 HMM-informed Transformer。当前版本只使用基础量价序列, 没有引入市场状态变量。后续可以将 HMM 的四个状态后验概率作为 market

regime 特征加入序列输入，检验市场状态是否能够帮助 Transformer 更好地理解不同市场环境下的量价信号。

第二，加入技术指标特征。Memo V2 中显示，技术指标虽然会降低 IC，但能够改善组合端指标，尤其是在叠加因果信号平滑后，组合风险调整收益有所提升。因此，下一步可以尝试将 MACD、KDJ、RSI、BOLL 等技术指标加入 Transformer 输入，观察其是否能够改善 Top-Bottom 收益和 Sharpe。

第三，对 Transformer 预测信号进行因果平滑。当前 Transformer 的 Top 组平均换手率为 25.29%，Bottom 组平均换手率为 23.45%，换手率仍然较高。Memo V2 中因果 EWM 平滑被证明是较有效的组合层优化方式，因此可以对 Transformer 输出的预测信号做半衰期 3 日或 5 日的因果平滑，检验其是否能够降低换手率、改善扣费后收益、Sharpe 和最大回撤。

9 总结

综合来看，V5 Transformer baseline 已经完成了老师提出的“尝试 Transformer 模型”的初步要求。该模型在严格因果的 V2 框架下，使用过去 20 日基础量价序列预测下一交易日收益，并在 walk-forward 样本外评估中获得了正向 Rank IC 和较稳定的多空收益。

实验结果表明，Transformer 相比 Kernel Ridge 和两层全连接 MLP 具有明显改善，说明序列建模和 Multi-Head Attention 确实能够提取一部分历史量价路径信息。但当前版本仍未超过 Ridge 线性基线，因此后续研究重点应放在特征扩展、HMM 状态融合和预测信号平滑上，而不是简单增加模型复杂度。